

# Cálculo Numérico

## Ajuste de Curvas pelo Método dos Quadrados Mínimos

UNESP - Universidade Estadual Paulista

São José do Rio Preto, SP.

Um ramo da Teoria da Aproximação se trata de **aproximar** e **obter informações** sobre funções que são

- definidas de uma maneira mais complicadas, ou
- definidas apenas em pontos ou em conjuntos limitados.

Neste sentido procuramos aproximar uma função  $f(x)$  por uma função mais simples  $G(x)$  de maneira que

- a diferença entre  $f(x)$  e sua aproximação  $G(x)$  seja mínima, e que
- a função  $G(x)$  seja mais fácil de ser manuseada do que a função  $f(x)$ .

O que queremos dizer quando falamos a diferença seja mínima?

No caso do *Método dos Quadrados Mínimos*, que é considerado nesta aula, o objetivo é minimizar a quantidade  $I$ , onde

**Caso Discreto:**

$$I = \sum_{j=1}^N [f(x_j) - G(x_j)]^2 w_j,$$

onde  $w_j$  em geral são pesos positivos.

- Caso mais simples:  $w_j = 1, j = 1, 2, \dots, n$ .

**Caso Contínuo:**

$$I = \int_a^b [f(x) - G(x)]^2 w(x) dx,$$

onde  $w(x)$  em geral é uma função-peso positiva.

- Caso mais simples:  $w(x) = 1$  em  $[a, b]$ .

$x$	-1.0	-0.6	-0.5	-0.3	0	0.2	0.4	0.5	1.0
$f(x)$	2.05	0.45	0.4	0.5	0	0.2	0.6	0.512	2.05

Uma forma de trabalhar com uma função definida por uma tabela de valores é o *Método dos Quadrados Mínimos*.

É aconselhável quando:

- a) é preciso obter um valor aproximado da função em algum ponto fora do intervalo de tabelamento.
- b) os valores tabelados poderão conter erro que, em geral, não são previsíveis.

Também é aconselhável quando precisamos expressar uma função mais complicada por uma função simples, como por exemplo, por um polinômio.

O problema do ajuste de curvas no caso em que temos uma tabela de pontos  $(x_1, f(x_1)), (x_2, f(x_2)), \dots, (x_N, f(x_N))$ , com  $x_1, x_2, \dots, x_N$  pertencentes a um intervalo  $[a, b]$ , consiste em:

“Escolhidas”  $n$  funções  $g_1(x), g_2(x), \dots, g_n(x)$ , contínuas em  $[a, b]$ , obter  $n$  constantes  $\alpha_1, \alpha_2, \dots, \alpha_n$  tais que a função

$$G(x) = \alpha_1 g_1(x) + \alpha_2 g_2(x) + \dots + \alpha_n g_n(x),$$

se aproxime ao máximo de  $f(x)$ .


Este é um modelo matemático linear porque os coeficientes a determinar  $\alpha_1, \alpha_2, \dots, \alpha_n$ , aparecem linearmente, embora as funções  $g_1(x), g_2(x), \dots, g_n(x)$  possam ser funções não lineares de  $x$ .

A escolha das função pode ser feita observando o gráfico dos pontos tabelados ou baseando-se em fundamentos teóricos do experimento que nos forneceu a tabela.

**Exemplo.** Considere a tabela de valores obtidas a partir de experimentos.

$x$	-1.0	-0.75	-0.6	-0.5	-0.3	0	0.2	0.4	0.5	0.7	1.0
$f(x)$	2.05	1.153	0.45	0.4	0.5	0	0.2	0.6	0.512	1.2	2.05

O diagrama de dispersão dos valores tabelados é:



É natural escolhermos uma função  $g_1(x) = x^2$  e procuramos então obter o valor de  $\alpha$  tal que  $G(x) = \alpha x^2$  aproxime ao máximo os valores tabelados.

No caso geral, escolhidas as funções  $g_1(x), g_2(x), \dots, g_n(x)$ , temos que estabelecer o conceito de proximidade entre as funções  $G(x)$  e  $f(x)$  para obter as constantes  $\alpha_1, \alpha_2, \dots, \alpha_n$ .

Algumas ideias são impor que

◇  $\max_{1 \leq j \leq N} |f(x_j) - G(x_j)|$  seja mínimo, or

◇  $\sum_{j=1}^N |f(x_j) - G(x_j)|$  seja mínimo.

No caso do *Método dos Quadrados Mínimos*, impomos que  $\alpha_1, \alpha_2, \dots, \alpha_n$  sejam determinados de forma que

•  $\sum_{j=1}^N [f(x_j) - G(x_j)]^2$  seja mínimo.

Considere a função  $f(x)$  dada pela tabela

$j$	1	2	$\dots$	$N$
$x_j$	$x_1$	$x_2$	$\dots$	$x_N$
$f(x_j)$	$f(x_1)$	$f(x_2)$	$\dots$	$f(x_N)$

Com as funções  $g_1, g_2, \dots, g_n$  escolhidas de alguma forma, o problema de obter a aproximação

$$G(x) = \alpha_1 g_1(x) + \alpha_2 g_2(x) + \dots + \alpha_n g_n(x),$$

tal que  $\sum_j^N [f(x_j) - G(x_j)]^2$  seja mínimo pode ser resolvido pelo sistema

$$\begin{bmatrix} a_{1,1} & a_{1,2} & \dots & a_{1,n} \\ a_{2,1} & a_{2,2} & \dots & a_{2,n} \\ \vdots & \vdots & & \vdots \\ a_{n,1} & a_{n,2} & \dots & a_{n,n} \end{bmatrix} \begin{bmatrix} \alpha_1 \\ \alpha_2 \\ \vdots \\ \alpha_n \end{bmatrix} = \begin{bmatrix} b_1 \\ b_2 \\ \vdots \\ b_n \end{bmatrix},$$

onde  $a_{i,k} = \sum_{j=1}^N g_i(x_j) g_k(x_j)$  e  $b_i = \sum_{j=1}^N g_i(x_j) f(x_j)$ .



Seja

$$\begin{aligned} F(\alpha_1, \alpha_2, \dots, \alpha_n) &= \sum_{j=1}^N [f(x_j) - G(x_j)]^2 \\ &= \sum_{j=1}^N \left[ f(x_j) - \sum_{k=1}^n \alpha_k g_k(x_j) \right]^2. \end{aligned}$$

Do Cálculo Diferencial sabemos que o mínimo de  $F(\alpha_1, \dots, \alpha_n)$ , ocorre em

$$\frac{\partial}{\partial \alpha_i} F(\alpha_1, \alpha_2, \dots, \alpha_n) = \frac{\partial}{\partial \alpha_i} \sum_{j=1}^N \left[ f(x_j) - \sum_{k=1}^n \alpha_k g_k(x_j) \right]^2 = 0,$$

para  $i = 1, 2, \dots, n$ . Fazendo o desenvolvimento, obtemos

$$\sum_{j=1}^N 2 \left[ f(x_j) - \sum_{k=1}^n \alpha_k g_k(x_j) \right] g_i(x_j) = 0,$$

para  $i = 1, 2, \dots, n$ .

As equações

$$\sum_{j=1}^N 2 \left[ f(x_j) - \sum_{k=1}^n \alpha_k g_k(x_j) \right] g_i(x_j) = 0,$$

para  $i = 1, 2, \dots, n$ , que podem ser escritas como

$$\sum_{j=1}^N \sum_{k=1}^n \alpha_k g_i(x_j) g_k(x_j) = \sum_{j=1}^N f(x_j) g_k(x_j),$$

para  $i = 1, 2, \dots, n$ .

Equivalentemente, podem ser escritas como

$$\sum_{k=1}^n \alpha_k \sum_{j=1}^N g_i(x_j) g_k(x_j) = \sum_{j=1}^N g_i(x_j) f(x_j),$$

para  $i = 1, 2, \dots, n$ .

A partir de

$$\sum_{k=1}^n \alpha_k \sum_{j=1}^N g_i(x_j) g_k(x_j) = \sum_{j=1}^N g_i(x_j) f(x_j),$$

para  $i = 1, 2, \dots, n$ , tomando

$$b_i = \sum_{j=1}^N g_i(x_j) f(x_j) \quad \text{e} \quad a_{i,k} = \sum_{j=1}^N g_i(x_j) g_k(x_j), \quad k = 1, 2, \dots, n,$$

e  $i = 1, 2, \dots, n$ , obtemos o sistema linear  $\mathbf{A}\mathbf{y} = \mathbf{b}$ , onde


$$\mathbf{A} = \begin{bmatrix} a_{1,1} & a_{1,2} & \cdots & a_{1,n} \\ a_{2,1} & a_{2,2} & \cdots & a_{2,n} \\ \vdots & \vdots & & \vdots \\ a_{n,1} & a_{n,2} & \cdots & a_{n,n} \end{bmatrix}, \quad \mathbf{y} = \begin{bmatrix} \alpha_1 \\ \alpha_2 \\ \vdots \\ \alpha_n \end{bmatrix} \quad \text{e} \quad \mathbf{b} = \begin{bmatrix} b_1 \\ b_2 \\ \vdots \\ b_n \end{bmatrix}.$$

Note que a matriz  $\mathbf{A}$  é simétrica, pois  $a_{i,k} = a_{k,i}$ .

Considere a tabela de valores obtidos a partir de um experimento.

$x$	0.0	0.25	0.4	0.5	0.7	1.0	1.2	1.4	1.5	1.7	2.0
$f(x)$	-1.0	-0.88	-0.68	-0.51	-0.02	1.0	1.87	2.93	3.49	4.77	7.1

O diagrama de dispersão dos valores tabelados mostra que a tabela representa uma parábola do tipo  $a + bx^2$ .



### Exemplo 1. Valores tabelados:

$x$	0.0	0.25	0.4	0.5	0.7	1.0	1.2	1.4	1.5	1.7	2.0
$f(x)$	-1.0	-0.88	-0.68	-0.51	-0.02	1.0	1.87	2.93	3.49	4.77	7.1

Portanto, escolhemos  $G(x) = \alpha_1 g_1(x) + \alpha_2 g_2(x)$ , onde

$$g_1(x) = 1 \quad \text{e} \quad g_2(x) = x^2.$$

Primeiro determinarmos os valores

$$a_{i,k} = \sum_{j=1}^N g_i(x_j) g_k(x_j) \quad \text{e} \quad b_i = \sum_{j=1}^N g_i(x_j) f(x_j),$$

para  $k = 1, 2$  e  $i = 1, 2$ .

Aqui  $N = 11$  é o número de pontos na tabela.

Depois resolvemos o sistema de equações lineares

$$\begin{bmatrix} a_{1,1} & a_{1,2} \\ a_{2,1} & a_{2,2} \end{bmatrix} \begin{bmatrix} \alpha_1 \\ \alpha_2 \end{bmatrix} = \begin{bmatrix} b_1 \\ b_2 \end{bmatrix}.$$

Para facilitar os cálculos, consideramos a tabela com índices e valores informados:

$j$	1	2	3	4	5	6	7	8	9	10	11
$x_j$	0.0	0.25	0.4	0.5	0.7	1.0	1.2	1.4	1.5	1.7	2.0
$f(x_j)$	-1.0	-0.88	-0.68	-0.51	-0.02	1.0	1.87	2.93	3.49	4.77	7.1

Assim, obtemos

$$\begin{aligned} b_1 &= \sum_{j=1}^{11} g_1(x_j) f(x_j) = \sum_{j=1}^{11} f(x_j) \\ &= [(-1.0) + (-0.88) + (-0.68) + (-0.51) + (-0.02) \\ &\quad + 1.0 + 1.87 + 2.93 + 3.49 + 4.77 + 7.1] \\ &= 18.07, \end{aligned}$$

$$\begin{aligned} b_2 &= \sum_{j=1}^{11} g_2(x_j) f(x_j) = \sum_{j=1}^{11} x_j^2 f(x_j) \\ &= [(0.0)^2 \times (-1.0) + (0.25)^2 \times (-0.88) + (0.4)^2 \times (-0.68) \\ &\quad + (0.5)^2 \times (-0.51) + (0.7)^2 \times (-0.02) + (1.0)^2 \times 1.0 + (1.2)^2 \times 1.87 \\ &\quad + (1.4)^2 \times 2.93 + (1.5)^2 \times 3.49 + (1.7)^2 \times 4.77 + (2.0)^2 \times 7.1] \\ &= 59.1723, \end{aligned}$$

## Exemplo 1.

$$a_{1,1} = \sum_{j=1}^{11} g_1(x_j)g_1(x_j) = \sum_{j=1}^{11} 1 = 11,$$

$$\begin{aligned} a_{2,1} = a_{1,2} &= \sum_{j=1}^{11} g_1(x_j)g_2(x_j) = \sum_{j=1}^{11} (x_j)^2 \\ &= [(0.0)^2 + (0.25)^2 + (0.4)^2 + (0.5)^2 + (0.7)^2 \\ &\quad + (1.0)^2 + (1.2)^2 + (1.4)^2 + (1.5)^2 + (1.7)^2 + (2.0)^2] \\ &= 14.5025, \end{aligned}$$

$$\begin{aligned} a_{2,2} &= \sum_{j=1}^{11} g_2(x_j)g_2(x_j) = \sum_{j=1}^{11} (x_j)^4 \\ &= [(0.0)^4 + (0.25)^4 + (0.4)^4 + (0.5)^4 + (0.7)^4 \\ &\quad + (1.0)^4 + (1.2)^4 + (1.4)^4 + (1.5)^4 + (1.7)^4 + (2.0)^4] \\ &= 36.66190625 \end{aligned}$$

**Exemplo 1.** Com os valores de  $b_i$  e  $a_{i,k}$  obtidos temos o sistema de equações:

$$\begin{bmatrix} 11.0 & 14.5025 \\ 14.5025 & 36.66190625 \end{bmatrix} \begin{bmatrix} \alpha_1 \\ \alpha_2 \end{bmatrix} = \begin{bmatrix} 18.07 \\ 59.1723 \end{bmatrix}.$$

Resolvendo este sistema obtemos

$$\alpha_1 = -1.0140298190471946 \quad \text{e} \quad \alpha_2 = 2.0151234621285394.$$

Então, o polinômio quadrático

$$G(x) = -1.0140298190471946 + 2.0151234621285394 x^2$$

é que melhor aproxima a função  $f(x)$ , dada pela tabela, da forma


$$\sum_{j=0}^{11} [f(x_j) - G(x_j)]^2 = \min_{a \in \mathbb{R}, b \in \mathbb{R}} \sum_{j=0}^{11} [f(x_j) - (a + b x_j^2)]^2.$$



Considere a tabela de valores obtidos a partir de um experimento.

$x_i$	-2	-1	0	1	2	3
$f(x_i)$	-7.5	-5.4	-1.5	1.5	3.5	7.3

O diagrama de dispersão dos valores tabelados mostra que a tabela representa uma reta  $a + bx$ .



## Exemplo 2.

Portanto, escolhermos que  $G(x) = \alpha_1 g_1(x) + \alpha_2 g_2(x)$ , onde

$$g_1(x) = 1 \quad \text{e} \quad g_2(x) = x.$$

Primeiro determinarmos os valores

$$a_{i,k} = \sum_{j=1}^N g_i(x_j) g_k(x_j) \quad \text{e} \quad b_i = \sum_{j=1}^N g_i(x_j) f(x_j),$$

para  $k = 1, 2$  e  $i = 1, 2$ . Aqui  $N = 6$  é o número de pontos na tabela.

$$a_{1,1} = \sum_{j=1}^6 g_1(x_j) g_1(x_j) = \sum_{j=1}^6 1 = 6.$$

$$a_{1,2} = \sum_{j=1}^6 g_1(x_j) g_2(x_j) = \sum_{j=1}^6 x_j = 3.$$

$$a_{2,2} = \sum_{j=1}^6 g_2(x_j) g_2(x_j) = \sum_{j=1}^6 x_j^2 = 19.$$

## Exemplo 2.

Matriz é simétrica  $a_{2,1} = a_{1,2} = 3$

$$b_1 = \sum_{j=1}^6 g_1(x_j) f(x_j) = \sum_{j=1}^6 f(x_j) = -2.1$$

$$b_2 = \sum_{j=1}^6 g_2(x_j) f(x_j) = \sum_{j=1}^6 x_j f(x_j) = 50.8$$

Agora resolvemos o sistema de equações lineares

$$\begin{bmatrix} a_{1,1} & a_{1,2} \\ a_{2,1} & a_{2,2} \end{bmatrix} \begin{bmatrix} \alpha_1 \\ \alpha_2 \end{bmatrix} = \begin{bmatrix} b_1 \\ b_2 \end{bmatrix}.$$

ou seja,

$$\begin{bmatrix} 6 & 3 \\ 3 & 19 \end{bmatrix} \begin{bmatrix} \alpha_1 \\ \alpha_2 \end{bmatrix} = \begin{bmatrix} -2.1 \\ 50.8 \end{bmatrix}.$$


Cuja solução é

$$\alpha_1 = -1.831428571 \quad \text{e} \quad \alpha_2 = 2.962857143$$

Assim, a reta

$$G(x) = -1.831428571 + 2.962857143x$$

é a reta que melhor aproxima os pontos dados pelo método dos mínimos quadrados. Veja o gráfico da reta e dos pontos dados.



No caso contínuo, o problema de ajuste de curvas consiste em:

dada uma função  $f(x)$  contínua num intervalo  $[a, b]$  e escolhidas as funções  $g_1(x), g_2(x), \dots, g_n(x)$  todas contínuas em  $[a, b]$ , determinar  $n$  constantes  $\alpha_1, \alpha_2, \dots, \alpha_n$  tais que a função

$$G(x) = \alpha_1 g_1(x) + \alpha_2 g_2(x) + \dots + \alpha_n g_n(x),$$

se aproxime ao máximo de  $f(x)$  no intervalo  $[a, b]$ .

Impormos que,  $\alpha_1, \alpha_2, \dots, \alpha_n$  sejam escolhidos de maneira que

- $\int_a^b [f(x) - G(x)]^2 dx$  seja mínimo.

Realizando o desenvolvimento do mesmo modo que foi feito no caso discreto, obtemos:

Dada a função  $f(x)$  definida em  $[a, b]$ , com as funções  $g_1, g_2, \dots, g_n$  escolhidas de alguma forma, o problema de obter a aproximação

$$G(x) = \alpha_1 g_1(x) + \alpha_2 g_2(x) + \dots + \alpha_n g_n(x),$$

tal que  $\int_a^b [f(x) - G(x)]^2 dx$  seja mínimo pode ser resolvido obtendo a solução do sistema

$$\begin{bmatrix} a_{1,1} & a_{1,2} & \cdots & a_{1,n} \\ a_{2,1} & a_{2,2} & \cdots & a_{2,n} \\ \vdots & \vdots & & \vdots \\ a_{n,1} & a_{n,2} & \cdots & a_{n,n} \end{bmatrix} \begin{bmatrix} \alpha_1 \\ \alpha_2 \\ \vdots \\ \alpha_n \end{bmatrix} = \begin{bmatrix} b_1 \\ b_2 \\ \vdots \\ b_n \end{bmatrix},$$

onde

$$a_{i,k} = \int_a^b g_i(x) g_k(x) dx \quad \text{e} \quad b_i = \int_a^b g_i(x) f(x) dx.$$

**Exemplo.** Obter, entre todas as parábolas, aquela que fica “mais próxima” de  $f(x) = 4x^3$  no intervalo  $[0, 1]$ .

Escolher  $g_1(x) = 1$ ,  $g_2(x) = x$  e  $g_3(x) = x^2$ , e com isso, preciso encontrar os coeficientes  $\alpha_1$ ,  $\alpha_2$  e  $\alpha_3$  tais que a função

$$G(x) = \alpha_1 g_1(x) + \alpha_2 g_2(x) + \alpha_3 g_3(x) = \alpha_1 + \alpha_2 x + \alpha_3 x^2,$$

se aproxime ao máximo de  $4x^3$ .

Desenvolvimento:

$$b_1 = \int_0^1 g_1(x)f(x)dx = \int_0^1 4x^3 dx = [x^4]_0^1 = 1.$$

$$b_2 = \int_0^1 g_2(x)f(x)dx = \int_0^1 4x^4 dx = \left[\frac{4x^5}{5}\right]_0^1 = \frac{4}{5}.$$

$$b_3 = \int_0^1 g_3(x)f(x)dx = \int_0^1 4x^5 dx = \left[\frac{4x^6}{6}\right]_0^1 = \frac{2}{3}.$$

$$a_{1,1} = \int_0^1 g_1(x)g_1(x)dx = \int_0^1 1dx = [x]_0^1 = 1.$$

$$a_{2,1} = a_{1,2} = \int_0^1 g_1(x)g_2(x)dx = \int_0^1 x dx = \left[\frac{x^2}{2}\right]_0^1 = \frac{1}{2}.$$

$$a_{3,1} = a_{1,3} = \int_0^1 g_1(x)g_3(x)dx = \int_0^1 x^2 dx = \left[\frac{x^3}{3}\right]_0^1 = \frac{1}{3}.$$

$$a_{2,2} = \int_0^1 g_2(x)g_2(x)dx = \int_0^1 x^2 dx = \frac{1}{3}.$$

$$a_{3,2} = a_{2,3} = \int_0^1 g_2(x)g_3(x)dx = \int_0^1 x^3 dx = \left[\frac{x^4}{4}\right]_0^1 = \frac{1}{4}.$$

$$a_{3,3} = \int_0^1 g_3(x)g_3(x)dx = \int_0^1 x^4 dx = \left[\frac{x^5}{5}\right]_0^1 = \frac{1}{5}.$$


O sistema linear é então:



$$\begin{bmatrix} 1 & 1/2 & 1/3 \\ 1/2 & 1/3 & 1/4 \\ 1/3 & 1/4 & 1/5 \end{bmatrix} \begin{bmatrix} \alpha_1 \\ \alpha_2 \\ \alpha_n \end{bmatrix} = \begin{bmatrix} 1 \\ 4/5 \\ 2/3 \end{bmatrix}.$$

Resolvendo este sistema obtemos

$$\alpha_1 = 0.2, \quad \alpha_2 = -2.4, \quad \alpha_3 = 6.0$$



Uma observação.

Resolver o sistema

$$\begin{bmatrix} 1 & 1/2 & 1/3 \\ 1/2 & 1/3 & 1/4 \\ 1/3 & 1/4 & 1/5 \end{bmatrix} \begin{bmatrix} \alpha_1 \\ \alpha_2 \\ \alpha_n \end{bmatrix} = \begin{bmatrix} 1 \\ 4/5 \\ 2/3 \end{bmatrix}.$$

também é equivalente de resolver o sistema

$$\begin{bmatrix} 6 & 3 & 2 \\ 30 & 20 & 15 \\ 20 & 15 & 12 \end{bmatrix} \begin{bmatrix} \alpha_1 \\ \alpha_2 \\ \alpha_n \end{bmatrix} = \begin{bmatrix} 6 \\ 48 \\ 40 \end{bmatrix}.$$

**Exemplo.** Obter, entre todas as parábolas, aquela que fica “mais próxima” de  $f(x) = 4x^3$  no intervalo  $[0, 1]$ . Mas, agora escolhemos

$$g_1(x) = 1, \quad g_2(x) = 2x - 1 \quad \text{e} \quad g_3(x) = 6x^2 - 6x + 1.$$

Precisamos de encontrar os coeficientes  $\alpha_1$ ,  $\alpha_2$  e  $\alpha_3$  tais que a função

$$G(x) = \alpha_1 g_1(x) + \alpha_2 g_2(x) + \alpha_3 g_3(x) = a + bx + cx^2,$$

se aproxime ao máximo de  $4x^3$ .

Desenvolvimento:

$$b_1 = \int_0^1 g_1(x)f(x)dx = \int_0^1 4x^3 dx = \left[ \frac{4x^4}{4} \right]_0^1 = 1,$$

$$b_2 = \int_0^1 g_2(x)f(x)dx = \int_0^1 (2x - 1)4x^3 dx = \left[ \frac{8x^5}{5} - x^4 \right]_0^1 = \frac{3}{5},$$

$$b_3 = \int_0^1 g_3(x)f(x)dx = \int_0^1 (6x^2 - 6x + 1)4x^3 dx = \left[ \frac{24x^6}{6} - \frac{24x^5}{5} + \frac{4x^4}{4} \right]_0^1 = \frac{1}{5},$$

$$a_{1,1} = \int_0^1 g_1(x)g_1(x)dx = \int_0^1 1dx = [x]_0^1 = 1,$$

$$a_{2,1} = a_{1,2} = \int_0^1 g_1(x)g_2(x)dx = \int_0^1 (2x - 1)dx = \left[ \frac{2x^2}{2} - x \right]_0^1 = 0,$$

$$a_{3,1} = a_{1,3} = \int_0^1 g_1(x)g_3(x)dx = \int_0^1 (6x^2 - 6x + 1)dx = \left[ \frac{6x^3}{3} - \frac{6x^2}{2} + x \right]_0^1 = 0,$$

$$a_{2,2} = \int_0^1 g_2(x)g_2(x)dx = \int_0^1 (2x - 1)^2 dx = \left[ \frac{4x^3}{3} - \frac{4x^2}{2} + x \right]_0^1 = \frac{1}{3},$$

$$a_{3,2} = a_{2,3} = \int_0^1 g_2(x)g_3(x)dx = \int_0^1 (2x - 1)(6x^2 - 6x + 1)dx = \dots = 0,$$

$$a_{3,3} = \int_0^1 g_3(x)g_3(x)dx = \int_0^1 (6x^2 - 6x + 1)^2 dx = \dots = \frac{1}{5}$$

O sistema linear é então

$$\begin{bmatrix} 1 & 0 & 0 \\ 0 & 1/3 & 0 \\ 0 & 0 & 1/5 \end{bmatrix} \begin{bmatrix} \alpha_1 \\ \alpha_2 \\ \alpha_n \end{bmatrix} = \begin{bmatrix} 1 \\ 3/5 \\ 1/5 \end{bmatrix}.$$

Resolvendo este sistema obtemos

$$\alpha_1 = 1, \quad \alpha_2 = \frac{9}{5} = 1.8, \quad \alpha_3 = 1$$

Então,

$$\begin{aligned} G(x) &= \alpha_1 g_1(x) + \alpha_2 g_2(x) + \alpha_3 g_3(x) = 1 + 1.8(2x - 1) + (6x^2 - 6x + 1) \\ &= 0.2 - 2.4x + 6x^2. \end{aligned}$$

Vimos no caso discreto que, quando queremos encontrar a reta  $G(x) = \alpha_1 + \alpha_2 x$  que melhor aproxima uma função  $f(x)$ , escolhemos  $g_1(x) = 1$ ,  $g_2(x) = x$  e resolvemos o sistema

$$\begin{bmatrix} a_{1,1} & a_{1,2} \\ a_{2,1} & a_{2,2} \end{bmatrix} \begin{bmatrix} \alpha_1 \\ \alpha_2 \end{bmatrix} = \begin{bmatrix} b_1 \\ b_2 \end{bmatrix},$$

ou seja, resolvemos

$$\begin{bmatrix} N & \sum_{j=1}^N x_j \\ \sum_{j=1}^N x_j & \sum_{j=1}^N x_j^2 \end{bmatrix} \begin{bmatrix} \alpha_1 \\ \alpha_2 \end{bmatrix} = \begin{bmatrix} \sum_{j=1}^N f(x_j) \\ \sum_{j=1}^N x_j f(x_j) \end{bmatrix}.$$

Há outros casos que podem ser convertidos na solução de um sistema  $2 \times 2$ .

1) Dados  $N$  valores de uma função  $f$ , queremos encontrar uma função  $G$  que melhor aproxima  $f(x)$ , tal que

$$G(x) = ae^{bx},$$

ou seja, precisamos determinar  $a$  e  $b$ .

- Vamos transformar a função não linear  $G(X)$  em um função linear aplicando  $\ln$  em ambos os lados, assim

$$\ln(G(x)) = \ln(ae^{bx})$$

$$\ln(G(x)) = \ln(a) + \ln(e^{bx})$$

$$\ln(G(x)) = \ln(a) + bx.$$

- Denotamos  $h(x) = \ln(G(x))$  que é uma reta e temos que determinar  $\alpha_1 = \ln(a)$  e  $\alpha_2 = b$ , ou seja determinar a reta

$$h(x) = \alpha_1 + \alpha_2 x.$$

Como a função  $G(x)$  foi “linearizada” também precisamos “linearizar” os valores dados da função  $f(x)$ , ou seja, vamos usar os valores  $\ln(f(x_j))$ .

Lembre-se: vamos encontrar  $h(x) = \ln(G(x))$  que aproxima  $\ln(f(x))$ , assim,  $G(x)$  aproxima  $f(x)$ .

**Exemplo:** Ajustar os pontos abaixo por uma função do tipo  $G(x) = ae^{bx}$ .

$x_j$	0.1	1.5	3.3	4.5	5.0
$f(x_j)$	5.9	8.8	12.0	19.8	21.5

Vamos ajustar  $\ln(f(x))$  por  $h(x) = \ln(G(x)) = \alpha_1 + \alpha_2 x$ ,

onde  $\alpha_1 = \ln(a) \Rightarrow a = e^{\alpha_1}$  e  $b = \alpha_2$ .



Calculamos os valores de  $\ln(f(x_j))$ :

$x_j$	0.1	1.5	3.3	4.5	5.0
$f(x_j)$	5.9	8.8	12.0	19.8	21.5
$\ln(f(x_j))$	1.77	2.17	2.48	2.99	3.07

e resolver o sistema

$$\begin{bmatrix} N & \sum_{j=1}^N x_j \\ \sum_{j=1}^N x_j & \sum_{j=1}^N x_j^2 \end{bmatrix} \begin{bmatrix} \alpha_1 \\ \alpha_2 \end{bmatrix} = \begin{bmatrix} \sum_{j=1}^N \ln(f(x_j)) \\ \sum_{j=1}^N x_j \ln(f(x_j)) \end{bmatrix},$$

ou seja

$$\begin{bmatrix} 5 & 14.4 \\ 14.4 & 58.4 \end{bmatrix} \begin{bmatrix} \alpha_1 \\ \alpha_2 \end{bmatrix} = \begin{bmatrix} 12.48 \\ 40.42 \end{bmatrix}.$$

Cuja solução é

$$\alpha_1 = 1.734215501 \quad \text{e} \quad \alpha_2 = 0.2645085066$$

Logo,

$$a = e^{\alpha_1} = e^{1.734215501} = 5.664482280$$

e

$$b = \alpha_2 = 0.2645085066$$

e a função  $G(x)$  que melhor aproxima  $f(x)$  é dada por

$$G(x) = 5.664482280 e^{0.2645085066 x}.$$

Outras transformações possíveis são

2)

$$G(x) = \frac{1}{a + bx} \Rightarrow h(x) = \frac{1}{G(x)} = a + bx = \alpha_1 + \alpha_2 x,$$

usando os valores de  $\frac{1}{f(x_j)}$  encontra-se a reta  $h(x)$ , e os valores  $a$  e  $b$  são obtidos por  $a = \alpha_1$  e  $b = \alpha_2$ .

3)

$$G(x) = ab^x \Rightarrow h(x) = \ln(G(x)) = \ln(a) + \ln(b)x = \alpha_1 + \alpha_2 x,$$

usando os valores de  $\ln(f(x_j))$  encontra-se a reta  $h(x)$ , e os valores  $a$  e  $b$  são obtidos por  $a = e^{\alpha_1}$  e  $b = e^{\alpha_2}$ .

4)

$$G(x) = e^{a+bx} \Rightarrow h(x) = \ln(G(x)) = a + bx = \alpha_1 + \alpha_2 x,$$

usando os valores de  $\ln(f(x_j))$  encontra-se a reta  $h(x)$ , e os valores  $a$  e  $b$  são obtidos por  $a = \alpha_1$  e  $b = \alpha_2$ .

5)

$$G(x) = ax^b \Rightarrow h(x) = \ln(G(x)) = \ln(a) + b \ln(x) = \alpha_1 + \alpha_2 t,$$

neste caso temos que usar os valores de  $\ln(f(x_j))$

e também os valores de  $\ln(x_j)$ , pois a variável depois da transformação é  $\ln(x)$ .

Então, encontra-se a reta  $h(x)$ , e os valores  $a$  e  $b$  são obtidos por  $a = e^{\alpha_1}$   
 $b = \alpha_2$ .

Ajustar os pontos abaixo por uma função do tipo  $G(x) = ax^b$ .

$x_j$	1	1.5	2	2.5	3
$f(x_j)$	3	23	96	293	729

Como  $G(x) = ax^b \Rightarrow h(x) = \ln(G(x)) = \ln(a) + b \ln(x) = \alpha_1 + \alpha_2 t$ ,  
precisamos calcular  $t_j = \ln(x_j)$  e  $\ln(f(x_j))$

$t_j = \ln(x_j)$	0	0.41	0.69	0.92	1.1
$\ln(f(x_j))$	1.1	3.14	4.56	5.68	6.59

e resolver o sistema

$$\begin{bmatrix} N & \sum_{j=1}^N t_j \\ \sum_{j=1}^N t_j & \sum_{j=1}^N t_j^2 \end{bmatrix} \begin{bmatrix} \alpha_1 \\ \alpha_2 \end{bmatrix} = \begin{bmatrix} \sum_{j=1}^N \ln(f(x_j)) \\ \sum_{j=1}^N t_j \ln(f(x_j)) \end{bmatrix},$$

ou seja e resolver o sistema

$$\begin{bmatrix} 5 & 3.12 \\ 3.12 & 2.7006 \end{bmatrix} \begin{bmatrix} \alpha_1 \\ \alpha_2 \end{bmatrix} = \begin{bmatrix} 21.07 \\ 16.9084 \end{bmatrix},$$

cuja solução é

$$\alpha_1 = 1.1006 \quad \text{e} \quad \alpha_2 = 4.9895$$

Para encontrar os valores de  $a$  e  $b$  fazemos

$$a = e^{\alpha_1} = e^{1.1006} = 3.006$$

e

$$b = \alpha_2 = 4.9895$$

e a função  $G$  do tipo  $ax^b$ , que melhor aproxima  $f$  é dada por

$$G(x) = 3.006 x^{4.9895}.$$

Gráfico dos pontos de  $f(x)$  em azul

$x_j$	1	1.5	2	2.5	3
$f(x_j)$	3	23	96	293	729

e da função  $G(x) = 3.006 x^{4.9895}$  em vermelho

